I M A G E L I N K P R E S E R V A T I O N

Сохранение ссылок на изображения при миграции

WordPress → Motors · Аудит ссылок, реестры и стратегия переноса

Сайт: caranddriver.ru

Репозиторий: github.com/goland186/wp · ветка migration/audit-2026-11-09

Статус: реестры готовы, ожидается загрузка папки uploads

Дата: 09.11.2026

Содержание

1. Резюме: состояние ссылок и вердикт.....1

2. Контекст и задача сохранения ссылок.....1

3. Исходные данные и методика аудита.....2

4. Инвентаризация ссылок на изображения.....2

4.1. Медиатека: вложения и их атрибуты.....3

4.2. Ссылки в текстах записей.....3

4.3. Внешние хотлинки.....4

4.4. Ссылки в настройках темы и плагинов.....4

4.5. Полный список файлов uploads.....4

5. Риски для ссылок при миграции.....5

5.1. Смешанный протокол http/https.....5

5.2. Потеря файлов при загрузке uploads.....5

5.3. Внешние хотлинки.....6

5.4. Сериализованные данные в настройках.....6

6. Стратегия сохранения ссылок: семь правил.....6

7. Нормализация URL: объём правок и порядок выполнения.....7

8. Сверка файлов при загрузке папки uploads.....8

9. Реестры и артефакты аудита.....9

10. Открытые вопросы и следующие шаги.....9

Примечание: содержание построено на кодах полей. После редактирования документа щёлкните по содержанию правой кнопкой мыши и выберите «Обновить поле», чтобы актуализировать номера страниц.

1. Резюме: состояние ссылок и вердикт

Настоящий документ фиксирует результаты аудита ссылок на изображения сайта caranddriver.ru и определяет стратегию их сохранения при миграции на новую платформу (актуальный WordPress с темой Motors). Работа выполнена до передачи папки uploads: поскольку её объём велик, файлы будут загружены отдельно, и главная задача на текущем этапе — зафиксировать в реестрах каждую актуальную ссылку, чтобы затем проверить полноту переноса файлов.

Медиатека насчитывает 8 121 вложение, а с учётом автоматически сгенерированных размерных вариантов ожидается 67 769 физических файлов в wp-content/uploads. В текстах 1 210 записей найдено 9 310 ссылок на изображения; 53,1% внутренних ссылок в тегах img используют протокол http:// и подлежат нормализации на https. Ещё 2 397 уникальных URL ссылаются на внешние сайты (хотлинки), прежде всего на expertmotor.ru.

Вердикт: все ссылки сохраняемы. Ключевые условия — перенос файлов uploads с сохранением структуры каталогов «один в один», сохранение идентификаторов вложений при переносе базы и нормализация 3 159 ссылок http → https. Реестры ссылок подготовлены и готовы к использованию на этапе загрузки файлов: **покрытие должно составить 100% от списка из 67 769 путей**.

2. Контекст и задача сохранения ссылок

Сайт caranddriver.ru (автомобильный портал, 1 198 опубликованных статей) переносится с устаревшей конфигурации WordPress с темой ColorMag на актуальный WordPress с коммерческой темой Motors. По требованиям проекта содержимое переносится полностью: статьи, страницы, рубрики, меню, SEO-метаданные, формы и подписки не должны пострадать, а URL остаются прежними.

Изображения — самая уязвимая часть такой миграции. Ссылки на картинки встречаются в четырёх независимых хранилищах: в текстах записей (post_content), в метаданных вложений, в настройках темы и плагинов (сериализованные массивы) и в физических файлах папки uploads. Ошибка в любом из этих хранилищ приводит к битым картинкам, которые не всегда заметны при беглой проверке.

Папка uploads не передана в репозиторий из-за объёма (десятки тысяч файлов) и будет загружена отдельно. Поэтому аудит ссылок выполнен полностью по базе данных: зафиксирован каждый URL, а ожидаемый список файлов сформирован и будет использован как эталон при приёмке загруженной папки. Такой порядок исключает ситуацию, когда ссылка есть, а файла нет.

3. Исходные данные и методика аудита

Источником послужил дамп базы данных old_dump.sql объёмом 64,7 МБ из репозитория github.com/goland186/wp (ветка main). Дамп конвертирован в SQLite для анализа (37 таблиц, префикс wpla_); исходный файл при этом не изменялся. Состав таблиц соответствует WordPress 4.9 с плагинами Yoast SEO, Slideshow Gallery, Simple Ads Manager и другими.

Извлечение ссылок выполнено тремя скриптами. Первый (extract_image_urls.py) собирает URL из всех текстовых источников: guid вложений, поля _wp_attached_file и _wp_attachment_metadata, теги img (src и srcset), ссылки a@href на файлы uploads, значения postmeta, options, таблиц плагина галерей, Yoast и termmeta. Второй (extract_size_variants.py) разбирает сериализованные метаданные и восстанавливает полный список файлов вместе с размерными вариантами. Третий (compare_uploads.py) готов к сверке фактической папки uploads с эталонным списком.

В анализ включены только актуальные состояния записей: 1 210 публикаций и страниц (статусы publish, draft, private, pending). Ревизии (1 801 запись) исключены как не влияющие на рабочий сайт. Протокол-относительные ссылки (//caranddriver.ru/…) и битые схемы (http:///…) в контенте не обнаружены.

4. Инвентаризация ссылок на изображения

4.1. Медиатека: вложения и их атрибуты

Все 8 121 вложение имеют корректный относительный путь в поле _wp_attached_file (стандарт WordPress: год/месяц/имя-файла), что упрощает перенос — пути не требуют пересчёта. Альтернативный текст (alt) заполнен лишь у 1 118 вложений (13,8%); это не влияет на сохранность ссылок, но сказывается на SEO, и после миграции alt стоит дособрать по названиям файлов.

Таблица 1. Состав медиатеки по типу содержимого

Тип (MIME)	Количество	Доля
image/jpeg	7 716	95,0%
image/png	381	4,7%
image/gif	19	0,2%
video/mp4	4	0,05%
image/tiff	1	0,01%

Значения guid у вложений смешаны по протоколу: 4 252 ссылки записаны как http://caranddriver.ru/… и 3 869 как https://caranddriver.ru/…. На рендеринг сайта guid не влияет, поэтому guid не изменяется; важны только ссылки в контенте и мета-полях.

4.2. Ссылки в текстах записей

В post_content 1 210 записей найдено 7 889 тегов img и 9 310 ссылок на изображения с учётом атрибутов srcset и ссылок a@href. Внутренние ссылки (на caranddriver.ru) в атрибуте src распределены по протоколам неравномерно: 3 159 (53,1%) записаны по http:// и 2 795 по https://. Каждая ссылка http:// при открытии сайта проходит редирект на https — это лишний сетевой хоп и потенциальный источник предупреждений о смешанном содержимом.

Таблица 2. Ссылки на изображения в контенте по типам

Тип ссылки	Количество	Комментарий
img@src, http://caranddriver.ru	3 159	Нормализовать на https (см. раздел 7)
img@src, https://caranddriver.ru	2 795	Оставить без изменений
img@src, внешние сайты	1 776	Хотлинки, реестр externals (см. 4.3)
img@srcset (внутренние и внешние)	847	Обрабатываются той же заменой протокола
a@href на файлы uploads	733	Замена протокола охватывает и их

4.3. Внешние хотлинки

Найдено 2 397 уникальных URL изображений, размещённых на сторонних доменах: статьи портала вставляют картинки прямо с внешних источников. Крупнейший источник — expertmotor.ru (1 534 URL, 64% внешнего списка), далее следуют сервисы Livejournal (335) и Яндекс.Фотки (157). Последний сервис особенно уязвим: img-fotki.yandex.ru — закрытый сервис, и часть ссылок может уже не работать.

Таблица 3. Топ-10 внешних доменов в хотлинках

Домен	URL, шт.	Примечание
expertmotor.ru	1 534	Автомобильный ресурс, основной внешний источник
ic.pics.livejournal.com	335	Импорт из ЖЖ
img-fotki.yandex.ru	157	Сервис закрыт, риск недоступности

Домен	URL, шт.	Примечание
blog.caranddriver.com	155	Американский аналог (внутренняя группа брендов)
ps.w.org	49	Официальные баннеры плагинов WordPress
media.club4x4.ru	27	Форум-сообщество
artemachkasov.com	21	Личный сайт автора
img.macos.ms	16	Прочие
st.motortrend.com	14	Зарубежные СМИ
Прочие 21 домен	89	Единичные ссылки

4.4. Ссылки в настройках темы и плагинов

В таблице options найдено 71 ссылка на изображения. Практически значимые источники: theme_mods_colormag (логотипы и иконки темы), три рекламных виджета ColorMag (баннеры 125×125, 300×250 и 728×90), layf_feed_logo (логотип для ленты) и car_demon_options. Таблицы плагина Slideshow Gallery существуют, но пусты — галереи не создавались, потерь по ним нет. Метаданные Yoast SEO не содержат ссылок на изображения (og:image формируется динамически от миниатюры записи). В postmeta записей — 10 ссылок, в termmeta — 0.

4.5. Полный список файлов uploads

Из метаданных вложений восстановлен полный перечень физических файлов: 8 121 оригинал плюс 67 761 размерный вариант — всего 67 769 путей. Самые массовые размеры соответствуют миниатюрам темы ColorMag и стандартным размерам WordPress: 130×90 (7 545 файлов), 150×150 (7 520), 390×205 (7 474), 392×272 (7 459) и 800×445 (6 192). Распределение по годам загрузки показано на рисунке 1: пик приходится на 2017 год (30,3% всех файлов).

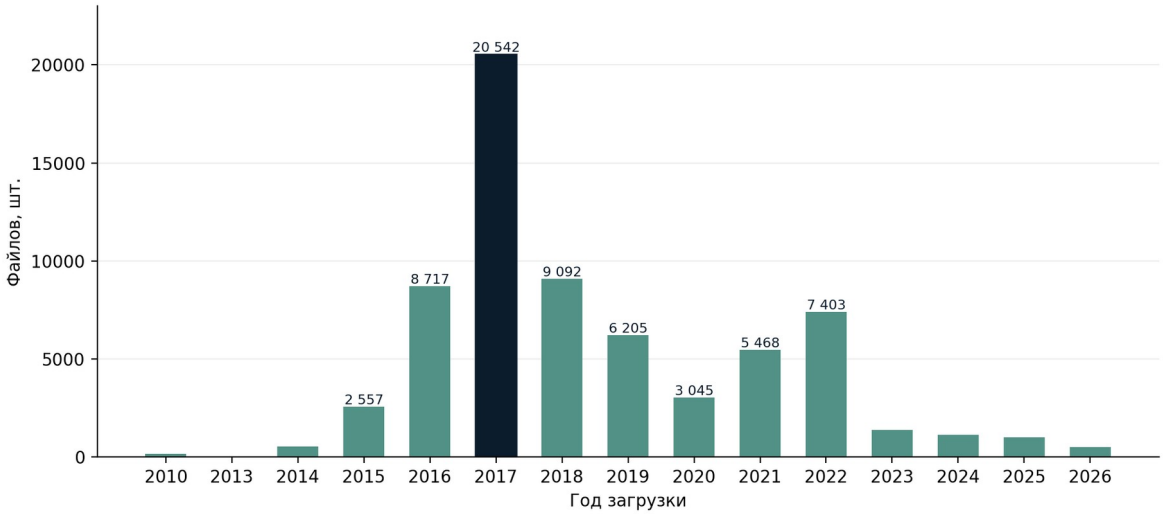


Рис. 1. Распределение 67 769 ожидаемых файлов uploads по годам загрузки

Для 491 размерного варианта не удалось однозначно сопоставить каталог размещения (вероятно, оригиналы удалены из медиатеки при жизни сайта). Список сохранён отдельно и будет уточнён при сверке: если соответствующих файлов в uploads нет, ссылки на них уже битые и до миграции их следует проверить отдельно.

5. Риски для ссылок при миграции

5.1. Смешанный протокол http/https

Больше половины внутренних ссылок в контенте (3 159 из 5 954) записаны по http://. Если оставить их как есть, каждая такая картинка будет запрашиваться по незащищённому протоколу и уходить в редирект; в ряде браузеров это порождает предупреждения о смешанном содержимом, а RSS-плагины Яндекса (Turbo и Zen) могут забирать изображения именно по ссылке из текста. Нормализация на https до переноса снимает риск целиком и не требует правки файлов.

5.2. Потеря файлов при загрузке uploads

67 769 файлов — объём, при котором частичная потеря при передаче статистически вероятна: обрывы соединения, лимиты архиватора, регистр букв в именах. Контрольная мера — эталонный список uploads_paths_expected_full.txt: после загрузки папки скрипт сравнения покажет точный процент покрытия и перечень недостающих файлов. Приёмка без этой сверки не проводится.

5.3. Внешние хотлинки

Ссылки на сторонние домены не контролируются переносом: они либо работают, либо нет — независимо от качества миграции. Риск сконцентрирован в img-

fotki.yandex.ru (закрытый сервис) и в мелких доменах. Стратегия на этапе миграции — сохранить как есть и зафиксировать список; решение о локализации (скачивании во вложения) принимается отдельно, поскольку требует осторожной обработки авторских прав.

5.4. Сериализованные данные в настройках

Настройки темы и виджетов хранятся в options как сериализованные PHP-массивы, где каждая строка сопровождается длиной s:N:…«…». Прямая замена текста в SQL меняет длину строки и молча ломает массив: сайт после этого может перестать читать настройки темы. Поэтому для таблицы options замена выполняется только через wp-cli search-replace, который пересчитывает длины, а сырой SQL применяется лишь к post_content и postmeta, где формат хранения не сериализован.

6. Стратегия сохранения ссылок: семь правил

Правила упорядочены по приоритету: первые три — обязательные условия приёмки, остальные — технические меры, реализуемые в порядке выполнения.

1. Домен не меняется — сайт остаётся на caranddriver.ru, поэтому абсолютные ссылки https://caranddriver.ru/wp-content/uploads/… продолжают работать без правки. Именно поэтому выбрана стратегия абсолютных URL, а не относительных путей: плагины RSS-лент Яндекса (Turbo, Zen) и почтовые рассылки требуют полных адресов.
2. Структура каталогов переносится «один в один»: uploads/ГГГГ/ММ/имя-файла не переименовывается, регистр букв сохраняется. Ни один файл не получает новое имя.
3. Идентификаторы вложений сохраняются: база переносится импортом дампа (а не XML-экспортом WXR, который пересобирает ID). Это сохраняет связи записей с миниатюрами и метаданными.
4. guid вложений не изменяется: WordPress не использует guid для рендеринга, а произвольная правка guid нарушает совместимость фидов и сторонних интеграций.
5. Протокол нормализуется на https: 3 159 ссылок в post_content, 4 записи postmeta и 8 записей options переводятся с http:// на https:// до включения новой платформы (порядок — в разделе 7).
6. Размерные варианты файлов переносятся полностью (67 769 путей). Если часть файлов не удастся передать, после сверки запускается wp media regenerate, пересоздающая миниатюры из оригиналов.

7. Внешние хотлинки на этапе миграции не скачиваются: 2 397 URL зафиксированы в реестре, решение о локализации каждого источника принимается отдельно с учётом авторских прав.

7. Нормализация URL: объём правок и порядок выполнения

Объём правок ограничен и полностью предсказуем: замена затрагивает 1 092 строки в четырёх таблицах. Нормализация выполняется на копии базы до импорта в новый WordPress; контрольные запросы до и после замены обязаны показать нули.

Таблица 4. Объём правок http → https по таблицам базы

Таблица	Строк с http://	Способ правки
wpla_posts (post_content)	1 084	SQL REPLACE — формат не сериализован
wpla_postmeta	4	SQL REPLACE
wpla_options	8	Только wp-cli search-replace (сериализация)
wpla_termmeta	0	Правка не требуется

Готовый скрипт с контрольными запросами сохранён в репозитории: scripts/sql/normalize_image_urls.sql. Для настроек темы используется wp-cli:

```
# Пересчитывает длины сериализованных строк, безопасно для options
wp search-replace 'http://www.caranddriver.ru' 'https://caranddriver.ru' --
all-tables --precise
wp search-replace 'http://caranddriver.ru' 'https://caranddriver.ru' --all-
tables --precise

# Перегенерация миниатюр — только если часть файлов не перенеслась
wp media regenerate --yes
```

Порядок выполнения: (1) поднять копию базы на новом окружении; (2) выполнить SQL-замены для posts/postmeta; (3) выполнить wp-cli для options; (4) запустить контрольные COUNT-запросы — все должны вернуть 0; (5) только после этого подключать папку uploads и тему Motors. Нормализация до подключения темы исключает кэширование старых http-ссылок.

8. Сверка файлов при загрузке папки uploads

Как только папка wp-content/uploads будет загружена в рабочее окружение или передана в проект, запускается скрипт сравнения. Он построчно сверяет фактические файлы с эталонным списком и формирует три артефакта: сводку с процентом покрытия, список недостающих файлов (есть ссылка — нет файла) и список избыточных (файл есть — ссылок в базе не найдено; они безвредны, но фиксируются для чистоты).

```
# Эталон: 67 769 путей из реестра ссылок
python3 scripts/compare_uploads.py /путь/к/uploads

# Результат: output/uploads_diff_report.json (покрытие, % и сводка)
#           output/uploads_missing.csv  (недостающие файлы)
#           output/uploads_extra.csv    (избыточные файлы)
```

Критерий приёмки — покрытие 100%: количество недостающих файлов равно нулю. Если покрытие ниже, недостающие позиции анализируются по месяцам (сводка отчёта группирует их по каталогам ГГГГ/ММ); утраченные оригиналы восстанавливаются из резервной копии, а утраченные миниатюры — командой wp media regenerate. Дополнительно выполняется выборочная проверка 20–30 статей из разных лет: изображения должны открываться по прямым ссылкам из реестра.

9. Реестры и артефакты аудита

Все реестры сохранены в репозитории goland186/wp, ветка migration/audit-2026-11-09, каталог images-registry/, и дублированы в рабочем окружении (wp-migration/output/). Формат CSV — с BOM, открывается в Excel без настройки кодировки.

Таблица 5. Состав реестра ссылок на изображения

Файл	Строк	Назначение
registry_attachments.csv	8 121	Все вложения: ID, путь, guid, alt, родитель
registry_urls_in_content.csv	9 310	Каждая ссылка в контенте с привязкой к записи
registry_external_images.csv	2 397	Хотлинки на внешние домены
uploads_paths_expected_full.txt	67 769	Эталонный список файлов uploads для сверки
uploads_paths_expected.txt	13 644	Прямые ссылки (без размерных вариантов)
uploads_paths_unresolved_variants.txt	491	Варианты без сопоставленного каталога
image_url_summary.json	—	Сводка аудита в машиночитаемом виде

Файл	Строк	Назначение
uploads_expected_stats.json	—	Статистика по размерам и годам

10. Открытые вопросы и следующие шаги

1. GitHub-доступ: коммит с реестрами создан локально (8 файлов, ветка migration/audit-2026-11-09), но push отклонён — токен, вшитый в remote-адрес, невалиден (401 Bad credentials). Требуется новый персональный токен с правом Contents: read/write на репозиторий goland186/wp; после его добавления в .env push выполняется одной командой.
2. Загрузка папки uploads: ожидается от заказчика. После загрузки — сверка по разделу 8 до 100% покрытия.
3. Решение по хотлинкам expertmotor.ru (1 534 URL) и img-fotki.yandex.ru (157 URL): оставить как есть или локализовать; для закрытого сервиса Яндекс.Фоток рекомендована проверка доступности до миграции.
4. Уточнение 491 неразобранного варианта размеров по факту сверки файлов.
5. Проверка 4 видеофайлов mp4 и 1 файла tiff: Motors и новый WordPress должны корректно отдавать их; tiff браузеры не отображают нативно — вероятно, конверсия в jpeg.
6. Дособор alt-текста (сейчас заполнен у 13,8% вложений) после основного переноса — отдельной задачей SEO-фазы.